Теория Вероятностей и Статистика Оценивание характеристик распределения

Потанин Богдан Станиславович

доцент, научный сотрудник, кандидат экономических наук

2023-2024

Оценивание характеристик распределения Мотивация

• Часто, сделать заранее достаточно точное предположение о семействе распределений, из которого была получена выборка, весьма затруднительно.

Оценивание характеристик распределения Мотивация

- Часто, сделать заранее достаточно точное предположение о семействе распределений, из которого была получена выборка, весьма затруднительно.
- Тем не менее, некоторые отдельные характеристики (вероятности, медиана, математическое ожидание и т.д.) можно оценить, не накладывая существенных допущений о распределении и даже не учитывая его параметры.

Оценивание характеристик распределения Мотивация

- Часто, сделать заранее достаточно точное предположение о семействе распределений, из которого была получена выборка, весьма затруднительно.
- Тем не менее, некоторые отдельные характеристики (вероятности, медиана, математическое ожидание и т.д.) можно оценить, не накладывая существенных допущений о распределении и даже не учитывая его параметры.
- Рассмотрим методы, позволяющие оценивать различные характеристики распределения без предварительного оценивания параметров и без предположений о конкретном семействе распределений.

Безусловные вероятности

ullet Имеется выборка $X_1,...,X_n$ из распределения $\Theta(heta).$

Безусловные вероятности

- ullet Имеется выборка $X_1,...,X_n$ из распределения $\Theta(heta).$
- Необходимо оценить вероятность $P(X_1 \in A)$, где $A \subset R$.

Безусловные вероятности

- Имеется выборка $X_1, ..., X_n$ из распределения $\Theta(\theta)$.
- ullet Необходимо оценить вероятность $P(X_1 \in A)$, где $A \subset R$.
- Несмещенная и состоятельная оценка данной вероятности может быть получена как доля наблюдений в выборке, принадлежащих множеству А:

$$\hat{P}(X_1 \in A) = rac{1}{n} \sum_{i=1}^n I(X_i \in A) \sim rac{1}{n} B(n, P(X_1 \in A))$$
 где: $I(X_i \in A) = egin{cases} 1, \ \text{если} \ X_i \in A \ 0, \ \text{в противном случаe} \end{cases} \sim Ber(P(X_1 \in A))$

Безусловные вероятности

- Имеется выборка $X_1, ..., X_n$ из распределения $\Theta(\theta)$.
- ullet Необходимо оценить вероятность $P(X_1 \in A)$, где $A \subset R$.
- Несмещенная и состоятельная оценка данной вероятности может быть получена как доля наблюдений в выборке, принадлежащих множеству *A*:

$$\hat{P}(X_1 \in A) = rac{1}{n} \sum_{i=1}^n I(X_i \in A) \sim rac{1}{n} B(n, P(X_1 \in A))$$
 где: $I(X_i \in A) = egin{cases} 1, \ \text{если} \ X_i \in A \ 0, \ \text{в противном случаe} \end{cases} \sim Ber(P(X_1 \in A))$

• Подставляя вместо наблюдений X_i их реализации x_i можно получить реализацию оценки соответствующей вероятности.

Безусловные вероятности

- Имеется выборка $X_1, ..., X_n$ из распределения $\Theta(\theta)$.
- ullet Необходимо оценить вероятность $P(X_1 \in A)$, где $A \subset R$.
- Несмещенная и состоятельная оценка данной вероятности может быть получена как доля наблюдений в выборке, принадлежащих множеству A:

$$\hat{P}(X_1 \in A) = rac{1}{n} \sum_{i=1}^n I(X_i \in A) \sim rac{1}{n} B(n, P(X_1 \in A))$$
 где: $I(X_i \in A) = egin{cases} 1, \ ext{ecли} \ X_i \in A \ 0, \ ext{в противном случаe} \end{cases} \sim Ber(P(X_1 \in A))$

• Подставляя вместо наблюдений X_i их реализации x_i можно получить реализацию оценки соответствующей вероятности.

Доказательство: докажем несмещенность и состоятельность рассматриваемой оценки вероятности:

$$E\left(\hat{P}(X_1 \in A)\right) = \frac{1}{n} \sum_{i=1}^n E\left(I(X_i \in A)\right) = \frac{1}{n} \sum_{i=1}^n P(X_i \in A) = \frac{1}{n} \times nP(X_1 \in A) = P(X_1 \in A)$$

Безусловные вероятности

- Имеется выборка $X_1, ..., X_n$ из распределения $\Theta(\theta)$.
- Необходимо оценить вероятность $P(X_1 \in A)$, где $A \subset R$.
- Несмещенная и состоятельная оценка данной вероятности может быть получена как доля наблюдений в выборке, принадлежащих множеству *A*:

$$\hat{P}(X_1 \in A) = rac{1}{n} \sum_{i=1}^n I(X_i \in A) \sim rac{1}{n} B(n, P(X_1 \in A))$$
 где: $I(X_i \in A) = egin{cases} 1, \ ext{если} \ X_i \in A \ 0, \ ext{в противном случаe} \end{cases} \sim Ber(P(X_1 \in A))$

• Подставляя вместо наблюдений X_i их реализации x_i можно получить реализацию оценки соответствующей вероятности.

Доказательство: докажем несмещенность и состоятельность рассматриваемой оценки вероятности:

$$E\left(\hat{P}(X_{1} \in A)\right) = \frac{1}{n} \sum_{i=1}^{n} E\left(I(X_{i} \in A)\right) = \frac{1}{n} \sum_{i=1}^{n} P(X_{i} \in A) = \frac{1}{n} \times nP(X_{1} \in A) = P(X_{1} \in A)$$

$$\lim_{n \to \infty} Var\left(\hat{P}(X_{1} \in A)\right) = \lim_{n \to \infty} \frac{1}{n^{2}} \sum_{i=1}^{n} Var\left(I(X_{i} \in A)\right) = \lim_{n \to \infty} \frac{n \times Var\left(I(X_{1} \in A)\right)}{n^{2}} = 0$$

Пример оценивания обычных вероятностей

Пример оценивания обычных вероятностей

$$\hat{P}(X_1=3)(x)=\frac{1}{5}\left(I(x_1=3)+I(x_2=3)+I(x_3=3)+I(x_4=3)+I(x_5=3)\right)=$$

Пример оценивания обычных вероятностей

$$\hat{P}(X_1 = 3)(x) = \frac{1}{5} (I(x_1 = 3) + I(x_2 = 3) + I(x_3 = 3) + I(x_4 = 3) + I(x_5 = 3)) =$$

$$= \frac{1}{5} (0 + 1 + 0 + 0 + 1) = \frac{2}{5} = 0.4$$

Пример оценивания обычных вероятностей

$$\hat{P}(X_1 = 3)(x) = \frac{1}{5} (I(x_1 = 3) + I(x_2 = 3) + I(x_3 = 3) + I(x_4 = 3) + I(x_5 = 3)) =$$

$$= \frac{1}{5} (0 + 1 + 0 + 0 + 1) = \frac{2}{5} = 0.4$$

$$\hat{P}(X_1 \ge 2.5)(x) = \frac{1}{5} (1 + 1 + 0 + 0 + 1) = \frac{3}{5} = 0.6$$

Пример оценивания обычных вероятностей

$$\hat{P}(X_1 = 3)(x) = \frac{1}{5} (I(x_1 = 3) + I(x_2 = 3) + I(x_3 = 3) + I(x_4 = 3) + I(x_5 = 3)) =$$

$$= \frac{1}{5} (0 + 1 + 0 + 0 + 1) = \frac{2}{5} = 0.4$$

$$\hat{P}(X_1 \ge 2.5)(x) = \frac{1}{5} (1 + 1 + 0 + 0 + 1) = \frac{3}{5} = 0.6$$

$$\hat{P}(X_1 = 2)(x) = \frac{1}{5} (0 + 0 + 0 + 0 + 0) = 0$$

Пример оценивания обычных вероятностей

$$\hat{P}(X_1 = 3)(x) = \frac{1}{5} (I(x_1 = 3) + I(x_2 = 3) + I(x_3 = 3) + I(x_4 = 3) + I(x_5 = 3)) =$$

$$= \frac{1}{5} (0 + 1 + 0 + 0 + 1) = \frac{2}{5} = 0.4$$

$$\hat{P}(X_1 \ge 2.5)(x) = \frac{1}{5} (1 + 1 + 0 + 0 + 1) = \frac{3}{5} = 0.6$$

$$\hat{P}(X_1 = 2)(x) = \frac{1}{5} (0 + 0 + 0 + 0 + 0) = 0$$

$$\hat{P}(-10 \le X_1 < 5)(x) = \frac{1}{5} (0 + 1 + 1 + 1 + 1) = \frac{4}{5} = 0.8$$

Пример оценивания обычных вероятностей

$$\hat{P}(X_1 = 3)(x) = \frac{1}{5} (I(x_1 = 3) + I(x_2 = 3) + I(x_3 = 3) + I(x_4 = 3) + I(x_5 = 3)) =$$

$$= \frac{1}{5} (0 + 1 + 0 + 0 + 1) = \frac{2}{5} = 0.4$$

$$\hat{P}(X_1 \ge 2.5)(x) = \frac{1}{5} (1 + 1 + 0 + 0 + 1) = \frac{3}{5} = 0.6$$

$$\hat{P}(X_1 = 2)(x) = \frac{1}{5} (0 + 0 + 0 + 0 + 0) = 0$$

$$\hat{P}(-10 \le X_1 < 5)(x) = \frac{1}{5} (0 + 1 + 1 + 1 + 1) = \frac{4}{5} = 0.8$$

$$\hat{P}(X_1 \in \{2, -2, 1\})(x) = \frac{1}{5} (0 + 0 + 1 + 1 + 0) = \frac{2}{5} = 0.4$$

Пример оценивания обычных вероятностей

$$\hat{P}(X_1 = 3)(x) = \frac{1}{5} (I(x_1 = 3) + I(x_2 = 3) + I(x_3 = 3) + I(x_4 = 3) + I(x_5 = 3)) =$$

$$= \frac{1}{5} (0 + 1 + 0 + 0 + 1) = \frac{2}{5} = 0.4$$

$$\hat{P}(X_1 \ge 2.5)(x) = \frac{1}{5} (1 + 1 + 0 + 0 + 1) = \frac{3}{5} = 0.6$$

$$\hat{P}(X_1 = 2)(x) = \frac{1}{5} (0 + 0 + 0 + 0 + 0) = 0$$

$$\hat{P}(-10 \le X_1 < 5)(x) = \frac{1}{5} (0 + 1 + 1 + 1 + 1) = \frac{4}{5} = 0.8$$

$$\hat{P}(X_1 \in \{2, -2, 1\})(x) = \frac{1}{5} (0 + 0 + 1 + 1 + 0) = \frac{2}{5} = 0.4$$

$$\hat{P}(X_1 \le 100)(x) = \frac{1}{5} (1 + 1 + 1 + 1 + 1) = \frac{5}{5} = 1$$

Условные вероятности

lacktriangle Имеется выборка $X_1,...,X_n$ из распределения $\Theta(heta).$

Условные вероятности

- lacktriangle Имеется выборка $X_1,...,X_n$ из распределения $\Theta(heta)$.
- ullet Необходимо оценить условную вероятность $P(X_1 \in A | X_1 \in B)$, где $A, B \subset R$ и $P(X_1 \in B) > 0$.

Условные вероятности

- Имеется выборка $X_1, ..., X_n$ из распределения $\Theta(\theta)$.
- ullet Необходимо оценить условную вероятность $P(X_1 \in A | X_1 \in B)$, где $A, B \subset R$ и $P(X_1 \in B) > 0$.
- Несмещенная и состоятельная оценка данной вероятности может быть получена как доля наблюдений в выборке, принадлежащих множеству $A \cap B$, среди наблюдений, принадлежащих B:

$$\hat{P}(X_1 \in A | X_1 \in B) = rac{1}{m} \sum_{i=1}^n I(X_i \in A \cap B) = rac{\hat{P}(X_1 \in A \cap B)}{\hat{P}(X_1 \in B)}$$
 , где $m = \sum_{i=1}^n I(X_i \in B)$

Условные вероятности

- lacktriangle Имеется выборка $X_1,...,X_n$ из распределения $\Theta(heta)$.
- ullet Необходимо оценить условную вероятность $P(X_1 \in A | X_1 \in B)$, где $A, B \subset R$ и $P(X_1 \in B) > 0$.
- Несмещенная и состоятельная оценка данной вероятности может быть получена как доля наблюдений в выборке, принадлежащих множеству $A \cap B$, среди наблюдений, принадлежащих B:

$$\hat{P}(X_1 \in A | X_1 \in B) = rac{1}{m} \sum_{i=1}^n I(X_i \in A \cap B) = rac{\hat{P}(X_1 \in A \cap B)}{\hat{P}(X_1 \in B)}$$
 , где $m = \sum_{i=1}^n I(X_i \in B)$

ullet Подставляя вместо наблюдений X_i их реализации x_i можно получить реализацию оценки соответствующей условной вероятности.

Условные вероятности

- lacktriangle Имеется выборка $X_1,...,X_n$ из распределения $\Theta(heta)$.
- ullet Необходимо оценить условную вероятность $P(X_1 \in A|X_1 \in B)$, где $A,B \subset R$ и $P(X_1 \in B) > 0$.
- Несмещенная и состоятельная оценка данной вероятности может быть получена как доля наблюдений в выборке, принадлежащих множеству $A \cap B$, среди наблюдений, принадлежащих B:

$$\hat{P}(X_1 \in A | X_1 \in B) = rac{1}{m} \sum_{i=1}^n I(X_i \in A \cap B) = rac{\hat{P}(X_1 \in A \cap B)}{\hat{P}(X_1 \in B)}$$
 , где $m = \sum_{i=1}^n I(X_i \in B)$

• Подставляя вместо наблюдений X_i их реализации x_i можно получить реализацию оценки соответствующей условной вероятности.

Доказательство: докажем состоятельность, используя теорему Слуцкого:

$$\begin{cases} \hat{P}(X_1 \in A \cap B) \xrightarrow{p} P(X_1 \in A \cap B) \\ \hat{P}(X_1 \in B) \xrightarrow{p} P(X_1 \in B) \end{cases} \implies \hat{P}(X_1 \in A \mid X_1 \in B) \xrightarrow{p} \frac{P(X_1 \in A \cap B)}{P(X_1 \in B)} = P(X_1 \in A \mid X_1 \in B)$$

Условные вероятности

- Имеется выборка $X_1, ..., X_n$ из распределения $\Theta(\theta)$.
- ullet Необходимо оценить условную вероятность $P(X_1 \in A | X_1 \in B)$, где $A, B \subset R$ и $P(X_1 \in B) > 0$.
- Несмещенная и состоятельная оценка данной вероятности может быть получена как доля наблюдений в выборке, принадлежащих множеству $A \cap B$, среди наблюдений, принадлежащих B:

$$\hat{P}(X_1 \in A | X_1 \in B) = rac{1}{m} \sum_{i=1}^n I(X_i \in A \cap B) = rac{\hat{P}(X_1 \in A \cap B)}{\hat{P}(X_1 \in B)}$$
 , где $m = \sum_{i=1}^n I(X_i \in B)$

• Подставляя вместо наблюдений X_i их реализации x_i можно получить реализацию оценки соответствующей условной вероятности.

Доказательство: докажем состоятельность, используя теорему Слуцкого:

$$\begin{cases} \hat{P}(X_1 \in A \cap B) \xrightarrow{p} P(X_1 \in A \cap B) \\ \hat{P}(X_1 \in B) \xrightarrow{p} P(X_1 \in B) \end{cases} \implies \hat{P}(X_1 \in A \mid X_1 \in B) \xrightarrow{p} \frac{P(X_1 \in A \cap B)}{P(X_1 \in B)} = P(X_1 \in A \mid X_1 \in B)$$

Пример: имеется реализация выборки x=(5,3,1,-2,3), найдем реализацию оценки $P(X_1 \le 3|X_1>0)$.

$$m = I(X_1 > 0) + ... + I(X_5 > 0) = 1 + 1 + 1 + 0 + 1 = 4$$

Условные вероятности

- Имеется выборка $X_1, ..., X_n$ из распределения $\Theta(\theta)$.
- ullet Необходимо оценить условную вероятность $P(X_1 \in A | X_1 \in B)$, где $A, B \subset R$ и $P(X_1 \in B) > 0$.
- Несмещенная и состоятельная оценка данной вероятности может быть получена как доля наблюдений в выборке, принадлежащих множеству $A \cap B$, среди наблюдений, принадлежащих B:

$$\hat{P}(X_1 \in A | X_1 \in B) = rac{1}{m} \sum_{i=1}^n I(X_i \in A \cap B) = rac{\hat{P}(X_1 \in A \cap B)}{\hat{P}(X_1 \in B)}$$
 , где $m = \sum_{i=1}^n I(X_i \in B)$

• Подставляя вместо наблюдений X_i их реализации x_i можно получить реализацию оценки соответствующей условной вероятности.

Доказательство: докажем состоятельность, используя теорему Слуцкого:

$$\begin{cases} \hat{P}(X_1 \in A \cap B) \xrightarrow{p} P(X_1 \in A \cap B) \\ \hat{P}(X_1 \in B) \xrightarrow{p} P(X_1 \in B) \end{cases} \implies \hat{P}(X_1 \in A \mid X_1 \in B) \xrightarrow{p} \frac{P(X_1 \in A \cap B)}{P(X_1 \in B)} = P(X_1 \in A \mid X_1 \in B)$$

Пример: имеется реализация выборки x=(5,3,1,-2,3), найдем реализацию оценки $P(X_1 \le 3|X_1>0)$.

$$m = I(X_1 > 0) + ... + I(X_5 > 0) = 1 + 1 + 1 + 0 + 1 = 4$$

$$\hat{P}(X_1 \leq 3 | X_1 > 0)(x) = \frac{1}{4} \left(I(0 < x_1 \leq 3) + \dots + I(0 < x_5 \leq 3) \right) = \frac{1}{4} \left(0 + 1 + 1 + 0 + 1 \right) = \frac{3}{4}$$

Выборочная (эмпирическая) функция распределения

• Выборочная (эмпирическая) функция распределения определяется как:

$$\hat{F}_n(t) = \hat{P}(X_1 \le t) = \frac{1}{n} \sum_{i=1}^n I(X_i \le t) \sim \frac{1}{n} B(n, P(X_1 \le t))$$

Выборочная (эмпирическая) функция распределения

• Выборочная (эмпирическая) функция распределения определяется как:

$$\hat{F}_n(t) = \hat{P}(X_1 \leq t) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq t) \sim \frac{1}{n} B(n, P(X_1 \leq t))$$

• Выборочная функция распределения в точке t является несмещенной и состоятельной оценкой функции распределения в этой же точке, то есть $\hat{F}_n(t) \stackrel{p}{\to} F_{X_1}(t), \forall t \in R$.

Выборочная (эмпирическая) функция распределения

• Выборочная (эмпирическая) функция распределения определяется как:

$$\hat{F}_n(t) = \hat{P}(X_1 \le t) = \frac{1}{n} \sum_{i=1}^n I(X_i \le t) \sim \frac{1}{n} B(n, P(X_1 \le t))$$

Выборочная (эмпирическая) функция распределения

• Выборочная (эмпирическая) функция распределения определяется как:

$$\hat{F}_n(t) = \hat{P}(X_1 \le t) = \frac{1}{n} \sum_{i=1}^n I(X_i \le t) \sim \frac{1}{n} B(n, P(X_1 \le t))$$

$$\hat{F}_n(t)|(X=x)=$$

Выборочная (эмпирическая) функция распределения

• Выборочная (эмпирическая) функция распределения определяется как:

$$\hat{F}_n(t) = \hat{P}(X_1 \le t) = \frac{1}{n} \sum_{i=1}^n I(X_i \le t) \sim \frac{1}{n} B(n, P(X_1 \le t))$$

$$\hat{F}_n(t)|(X=x)= egin{cases} (0+0+0+0+0)/5=0 ext{, eсли } t<-2 \end{cases}$$

Выборочная (эмпирическая) функция распределения

• Выборочная (эмпирическая) функция распределения определяется как:

$$\hat{F}_n(t) = \hat{P}(X_1 \le t) = \frac{1}{n} \sum_{i=1}^n I(X_i \le t) \sim \frac{1}{n} B(n, P(X_1 \le t))$$

$$|\hat{F}_n(t)|(X=x)= egin{cases} (0+0+0+0+0)/5=0, \ ext{если} \ t<-2 \ (0+0+0+1+0)/5=0.2, \ ext{если} \ -2 \leq t < 1 \end{cases}$$

Выборочная (эмпирическая) функция распределения

• Выборочная (эмпирическая) функция распределения определяется как:

$$\hat{F}_n(t) = \hat{P}(X_1 \leq t) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq t) \sim \frac{1}{n} B(n, P(X_1 \leq t))$$

$$|\hat{F}_n(t)|(X=x)= egin{cases} (0+0+0+0+0)/5=0, \ ext{если} \ t<-2 \ (0+0+0+1+0)/5=0.2, \ ext{если} \ -2\leq t<1 \ (0+0+1+1+0)/5=0.4, \ ext{если} \ 1\leq t<3 \end{cases}$$

Выборочная (эмпирическая) функция распределения

• Выборочная (эмпирическая) функция распределения определяется как:

$$\hat{F}_n(t) = \hat{P}(X_1 \leq t) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq t) \sim \frac{1}{n} B(n, P(X_1 \leq t))$$

$$\hat{F}_n(t) | (X=x) = egin{cases} (0+0+0+0+0)/5 = 0, \ ext{если} \ t < -2 \ (0+0+0+1+0)/5 = 0.2, \ ext{если} \ -2 \leq t < 1 \ (0+0+1+1+0)/5 = 0.4, \ ext{если} \ 1 \leq t < 3 \ (0+1+1+1+1)/5 = 0.8, \ ext{если} \ 3 \leq t < 5 \end{cases}$$

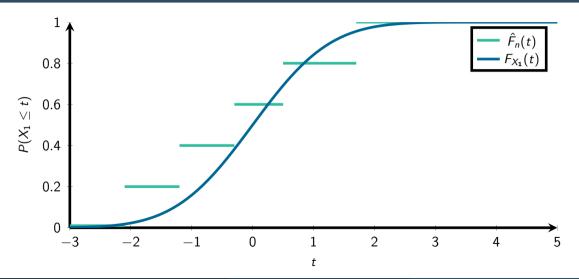
Выборочная (эмпирическая) функция распределения

• Выборочная (эмпирическая) функция распределения определяется как:

$$\hat{F}_n(t) = \hat{P}(X_1 \le t) = \frac{1}{n} \sum_{i=1}^n I(X_i \le t) \sim \frac{1}{n} B(n, P(X_1 \le t))$$

$$\hat{F}_n(t) | (X=x) = egin{cases} (0+0+0+0+0)/5 = 0, \ ext{если} \ t < -2 \ (0+0+0+1+0)/5 = 0.2, \ ext{если} \ -2 \leq t < 1 \ (0+0+1+1+0)/5 = 0.4, \ ext{если} \ 1 \leq t < 3 \ (0+1+1+1+1)/5 = 0.8, \ ext{если} \ 3 \leq t < 5 \ (1+1+1+1+1)/5 = 1, \ ext{если} \ t \geq 5 \end{cases}$$

График эмпирической функции распределения на фоне теоретической функции распределения



Верхняя граница погрешности

• Погрешность при использовании выборочной функции распределения вместо истинной можно записать как $|\hat{F}_n(t) - F_{X_1}(t)|$.

Оценивание вероятностей

Верхняя граница погрешности

- Погрешность при использовании выборочной функции распределения вместо истинной можно записать как $|\hat{F}_n(t) F_{X_1}(t)|$.
- При помощи неравенства Чебышева можно найти верхнюю границу для вероятности того, что соответствующая погрешность превысит определенное значение:

$$P(|\hat{F}_n(t) - F_{X_1}(t)| > \varepsilon) \le \frac{F_{X_1}(t)(1 - F_{X_1}(t))}{n\varepsilon^2} \le \frac{1}{4n\varepsilon^2}$$

Оценивание вероятностей

Верхняя граница погрешности

- Погрешность при использовании выборочной функции распределения вместо истинной можно записать как $|\hat{F}_n(t) F_{X_1}(t)|$.
- При помощи неравенства Чебышева можно найти верхнюю границу для вероятности того, что соответствующая погрешность превысит определенное значение:

$$P(|\hat{F}_n(t) - F_{X_1}(t)| > \varepsilon) \le \frac{F_{X_1}(t)(1 - F_{X_1}(t))}{n\varepsilon^2} \le \frac{1}{4n\varepsilon^2}$$

• Чем больше объем выборки n, тем меньше максимально возможная вероятность получить погрешность, превышающую ε .

Оценивание вероятностей

Верхняя граница погрешности

- Погрешность при использовании выборочной функции распределения вместо истинной можно записать как $|\hat{F}_n(t) F_{X_1}(t)|$.
- При помощи неравенства Чебышева можно найти верхнюю границу для вероятности того, что соответствующая погрешность превысит определенное значение:

$$P(|\hat{F}_n(t) - F_{X_1}(t)| > \varepsilon) \leq \frac{F_{X_1}(t)(1 - F_{X_1}(t))}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2}$$

- Чем больше объем выборки n, тем меньше максимально возможная вероятность получить погрешность, превышающую ε .
- Например, если объем выборки составляет n=1000000 миллион наблюдений, то вероятность того, что погрешность превысит $\varepsilon=0.01$ окажется меньше, чем:

$$\frac{1}{4 \times 1000000 \times 0.01^2} = 0.0025$$

Выборочные моменты

• Выборочное среднее \overline{X}_n является несмещенной и состоятельной оценкой математического ожидания $E(X_1)$.

Выборочные моменты

• Выборочное среднее \overline{X}_n является несмещенной и состоятельной оценкой математического ожидания $E(X_1)$.

Доказательство:

$$E(\overline{X}_n) = E(X_1)$$

Выборочные моменты

• Выборочное среднее \overline{X}_n является несмещенной и состоятельной оценкой математического ожидания $E(X_1)$.

Доказательство:

$$E(\overline{X}_n) = E(X_1)$$

$$\lim_{n \to \infty} Var(\overline{X}_n) = \lim_{n \to \infty} Var(X_1)/n = 0$$

Выборочные моменты

Доказательство:

• Выборочное среднее \overline{X}_n является несмещенной и состоятельной оценкой математического ожидания $E(X_1)$.

$E(\overline{X}_n) = E(X_1)$ $\lim_{n \to \infty} Var(\overline{X}_n) = \lim_{n \to \infty} Var(X_1)/n = 0$

• По аналогии несмещенные и состоятельные оценки начальных моментов $E(X_1^k)$, где $k \in N$, могут быть получены с использованием выборочных начальных моментов соответствующего порядка:

$$\hat{m}_k = \overline{X^k}_n = \frac{1}{n} \sum_{i=1}^n X_i^k$$

Выборочные моменты

• Выборочное среднее \overline{X}_n является несмещенной и состоятельной оценкой математического ожидания $E(X_1)$.

Доказательство:

$$E(\overline{X}_n) = E(X_1)$$

$$\lim_{n \to \infty} Var(\overline{X}_n) = \lim_{n \to \infty} Var(X_1)/n = 0$$

• По аналогии несмещенные и состоятельные оценки начальных моментов $E(X_1^k)$, где $k \in N$, могут быть получены с использованием выборочных начальных моментов соответствующего порядка:

$$\hat{m}_k = \overline{X^k}_n = \frac{1}{n} \sum_{i=1}^n X_i^k$$

Пример: рассчитаем реализацию третьего начального выборочного момента по выборке с реализациями x = (5, 2, 5):

$$\hat{m}_k(x) = \frac{1}{3} (5^3 + 2^3 + 5^3) = 86$$

Выборочная дисперсия

• Выборочная дисперсия рассчитывается как:

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2$$

Выборочная дисперсия

• Выборочная дисперсия рассчитывается как:

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2$$

ullet Она является смещенной, но состоятельной оценкой дисперсии $Var(X_1)$.

Выборочная дисперсия

• Выборочная дисперсия рассчитывается как:

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2$$

Выборочная дисперсия

• Выборочная дисперсия рассчитывается как:

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2$$

$$E(S_n^2) = \frac{1}{n} \sum_{i=1}^n E((X_i - \overline{X}_n)^2) = \frac{1}{n} \times nE((X_1 - \overline{X}_n)^2) = E((X_1 - \overline{X}_n)^2) = E($$

Выборочная дисперсия

• Выборочная дисперсия рассчитывается как:

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2$$

$$E(S_n^2) = \frac{1}{n} \sum_{i=1}^n E((X_i - \overline{X}_n)^2) = \frac{1}{n} \times nE((X_1 - \overline{X}_n)^2) = E((X_1 - \overline{X}_n)^2) =$$

$$= Var(X_1 - \overline{X}_n) + E(X_1 - \overline{X}_n)^2 = Var(X_1) + Var(\overline{X}_n) - 2Cov(X_1, \overline{X}_n) + 0^2 =$$

Выборочная дисперсия

• Выборочная дисперсия рассчитывается как:

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2$$

$$E(S_n^2) = \frac{1}{n} \sum_{i=1}^n E((X_i - \overline{X}_n)^2) = \frac{1}{n} \times nE((X_1 - \overline{X}_n)^2) = E((X_1 - \overline{X}_n)^2) =$$

$$= Var(X_1 - \overline{X}_n) + E(X_1 - \overline{X}_n)^2 = Var(X_1) + Var(\overline{X}_n) - 2Cov(X_1, \overline{X}_n) + 0^2 =$$

$$= Var(X_1) + \frac{Var(X_1)}{n} - 2Cov(X_1, \frac{1}{n}X_1) = Var(X_1) \times \left(1 + \frac{1}{n} - 2\frac{1}{n}\right) = \frac{n-1}{n} Var(X_1)$$

Выборочная дисперсия

• Выборочная дисперсия рассчитывается как:

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X}_n)^2$$

• Она является смещенной, но состоятельной оценкой дисперсии $Var(X_1)$. **Доказательство**: покажем, что оценка является смещенной:

$$\begin{split} E(S_n^2) &= \frac{1}{n} \sum_{i=1}^n E((X_i - \overline{X}_n)^2) = \frac{1}{n} \times nE((X_1 - \overline{X}_n)^2) = E((X_1 - \overline{X}_n)^2) = \\ &= Var(X_1 - \overline{X}_n) + E(X_1 - \overline{X}_n)^2 = Var(X_1) + Var(\overline{X}_n) - 2Cov(X_1, \overline{X}_n) + 0^2 = \\ &= Var(X_1) + \frac{Var(X_1)}{n} - 2Cov\left(X_1, \frac{1}{n}X_1\right) = Var(X_1) \times \left(1 + \frac{1}{n} - 2\frac{1}{n}\right) = \frac{n-1}{n}Var(X_1) \end{split}$$

• Состоятельная и несмещенная оценка дисперсии может быть получена с использование исправленной (скорректированной) выборочной дисперсии:

$$\hat{\sigma}^2 = \frac{n}{n-1} S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \overline{X}_n)^2$$

Вариационный ряд

• Обозначим через $X_{(i)}$ наблюдение, которое является i-м по величине в выборке. Оно называется i-й порядковой статистикой. Статистики $X_{(1)} = \min(X_1,...,X_n)$ и $X_{(n)} = \max(X_1,...,X_n)$ именуются минимальной и максимальной порядковыми статистиками соответственно.

Вариационный ряд

- Обозначим через $X_{(i)}$ наблюдение, которое является i-м по величине в выборке. Оно называется i-й порядковой статистикой. Статистики $X_{(1)} = \min(X_1,...,X_n)$ и $X_{(n)} = \max(X_1,...,X_n)$ именуются минимальной и максимальной порядковыми статистиками соответственно.
- lacktriangled Последовательность $X_{(1)},...,X_{(n)}$ именуется вариационным рядом.

Вариационный ряд

- Обозначим через $X_{(i)}$ наблюдение, которое является i-м по величине в выборке. Оно называется i-й порядковой статистикой. Статистики $X_{(1)} = \min(X_1,...,X_n)$ и $X_{(n)} = \max(X_1,...,X_n)$ именуются минимальной и максимальной порядковыми статистиками соответственно.
- lacktriangle Последовательность $X_{(1)},...,X_{(n)}$ именуется вариационным рядом.
- Распределение максимальной экстремальной статистики определяется как:

$$F_{X_{(n)}}(x) = F_{\max(X_1,...,X_n)}(x) = P(\max(X_1,...,X_n) \le x) = P(X_1 \le x,...,X_n \le x) = P(X_$$

Вариационный ряд

- Обозначим через $X_{(i)}$ наблюдение, которое является i-м по величине в выборке. Оно называется i-й порядковой статистикой. Статистики $X_{(1)} = \min(X_1,...,X_n)$ и $X_{(n)} = \max(X_1,...,X_n)$ именуются минимальной и максимальной порядковыми статистиками соответственно.
- Последовательность $X_{(1)},...,X_{(n)}$ именуется вариационным рядом.
- Распределение максимальной экстремальной статистики определяется как:

$$F_{X_{(n)}}(x) = F_{\max(X_1,...,X_n)}(x) = P(\max(X_1,...,X_n) \le x) = P(X_1 \le x,...,X_n \le x) =$$

$$= P(X_1 \le x) \times ... \times P(X_n \le x) = F_{X_1}(x) \times ... \times F_{X_n}(x) = (F_{X_1}(x))^n$$

Вариационный ряд

- Обозначим через $X_{(i)}$ наблюдение, которое является i-м по величине в выборке. Оно называется i-й порядковой статистикой. Статистики $X_{(1)} = \min(X_1,...,X_n)$ и $X_{(n)} = \max(X_1,...,X_n)$ именуются минимальной и максимальной порядковыми статистиками соответственно.
- Последовательность $X_{(1)},...,X_{(n)}$ именуется вариационным рядом.
- Распределение максимальной экстремальной статистики определяется как:

$$F_{X_{(n)}}(x) = F_{\max(X_1,...,X_n)}(x) = P(\max(X_1,...,X_n) \le x) = P(X_1 \le x,...,X_n \le x) =$$

$$= P(X_1 \le x) \times ... \times P(X_n \le x) = F_{X_1}(x) \times ... \times F_{X_n}(x) = (F_{X_1}(x))^n$$

• Распределение минимальной экстремальной статистики определяется как:

$$F_{X_{(\mathbf{1})}}(x) = F_{\min(X_{\mathbf{1}},...,X_n)}(x) = P(\min(X_{\mathbf{1}},...,X_n) \le x) = 1 - P(\min(X_{\mathbf{1}},...,X_n) > x) = 1 - P(\min(X_{\mathbf{1}},..$$

Вариационный ряд

- Обозначим через $X_{(i)}$ наблюдение, которое является i-м по величине в выборке. Оно называется i-й порядковой статистикой. Статистики $X_{(1)} = \min(X_1,...,X_n)$ и $X_{(n)} = \max(X_1,...,X_n)$ именуются минимальной и максимальной порядковыми статистиками соответственно.
- Последовательность $X_{(1)},...,X_{(n)}$ именуется вариационным рядом.
- Распределение максимальной экстремальной статистики определяется как:

$$F_{X_{(n)}}(x) = F_{\max(X_1,...,X_n)}(x) = P(\max(X_1,...,X_n) \le x) = P(X_1 \le x,...,X_n \le x) =$$

$$= P(X_1 \le x) \times ... \times P(X_n \le x) = F_{X_1}(x) \times ... \times F_{X_n}(x) = (F_{X_1}(x))^n$$

• Распределение минимальной экстремальной статистики определяется как:

$$F_{X_{(1)}}(x) = F_{\min(X_1,...,X_n)}(x) = P(\min(X_1,...,X_n) \le x) = 1 - P(\min(X_1,...,X_n) > x) = 1 - P(X_1 > x) \times ... \times P(X_n > x) = 1 - (1 - F_{X_1}(x)) \times ... \times (1 - F_{X_n}(x)) = 1 - (1 - F_{X_1}(x))^n$$

Вариационный ряд

- Обозначим через $X_{(i)}$ наблюдение, которое является i-м по величине в выборке. Оно называется i-й порядковой статистикой. Статистики $X_{(1)} = \min(X_1,...,X_n)$ и $X_{(n)} = \max(X_1,...,X_n)$ именуются минимальной и максимальной порядковыми статистиками соответственно.
- Последовательность $X_{(1)},...,X_{(n)}$ именуется вариационным рядом.
- Распределение максимальной экстремальной статистики определяется как:

$$F_{X_{(n)}}(x) = F_{\max(X_1,...,X_n)}(x) = P(\max(X_1,...,X_n) \le x) = P(X_1 \le x,...,X_n \le x) =$$

$$= P(X_1 \le x) \times ... \times P(X_n \le x) = F_{X_1}(x) \times ... \times F_{X_n}(x) = (F_{X_1}(x))^n$$

• Распределение минимальной экстремальной статистики определяется как:

$$F_{X_{(1)}}(x) = F_{\min(X_1,...,X_n)}(x) = P(\min(X_1,...,X_n) \le x) = 1 - P(\min(X_1,...,X_n) > x) =$$

$$= 1 - P(X_1 > x) \times ... \times P(X_n > x) = 1 - (1 - F_{X_1}(x)) \times ... \times (1 - F_{X_n}(x)) = 1 - (1 - F_{X_1}(x))^n$$

• Распределение і-й порядковой статистики определяется как:

$$F_{X_{(i)}}(x) = \sum_{k=i}^{n} C_n^k \left(1 - F_{X_1}(x) \right)^{n-k} \left(F_{X_1}(x) \right)^k$$

Вариационный ряд

- Обозначим через $X_{(i)}$ наблюдение, которое является i-м по величине в выборке. Оно называется i-й порядковой статистикой. Статистики $X_{(1)} = \min(X_1,...,X_n)$ и $X_{(n)} = \max(X_1,...,X_n)$ именуются минимальной и максимальной порядковыми статистиками соответственно.
- Последовательность $X_{(1)},...,X_{(n)}$ именуется вариационным рядом.
- Распределение максимальной экстремальной статистики определяется как:

$$F_{X_{(n)}}(x) = F_{\max(X_1,...,X_n)}(x) = P(\max(X_1,...,X_n) \le x) = P(X_1 \le x,...,X_n \le x) =$$

$$= P(X_1 \le x) \times ... \times P(X_n \le x) = F_{X_1}(x) \times ... \times F_{X_n}(x) = (F_{X_1}(x))^n$$

• Распределение минимальной экстремальной статистики определяется как:

$$F_{X_{(1)}}(x) = F_{\min(X_1,...,X_n)}(x) = P(\min(X_1,...,X_n) \le x) = 1 - P(\min(X_1,...,X_n) > x) =$$

$$= 1 - P(X_1 > x) \times ... \times P(X_n > x) = 1 - (1 - F_{X_1}(x)) \times ... \times (1 - F_{X_n}(x)) = 1 - (1 - F_{X_1}(x))^n$$

• Распределение *i*-й порядковой статистики определяется как:

$$F_{X_{(i)}}(x) = \sum_{k=i}^{n} C_n^k (1 - F_{X_1}(x))^{n-k} (F_{X_1}(x))^k$$

Пример: найдем вероятность того, что в выборке из n=5 экспоненциальных случайных величин с параметром $\lambda=0.2$ наибольшее значение не превысит 10:

$$F_{X_{(5)}}(10) = (1 - e^{-0.2 \times 10})^5 \approx 0.483$$

Гистограмма

• Гистограмма является оценкой функции плотности.

Гистограмма

- Гистограмма является оценкой функции плотности.
- ullet Разобьем выборку на m интервалов равной длины h, где интервал обозначим как b_k .

Гистограмма

- Гистограмма является оценкой функции плотности.
- ullet Разобьем выборку на m интервалов равной длины h, где интервал обозначим как b_k .
- ullet Гистограмма предполагает следующую (как правило смещенную) оценку функции плотности в точке $t \in b_k$:

$$\hat{f}_{X_i}(t) = \frac{1}{nh} \sum_{i=1}^n I(X_i \in b_k)$$

Гистограмма

- Гистограмма является оценкой функции плотности.
- ullet Разобьем выборку на m интервалов равной длины h, где интервал обозначим как b_k .
- ullet Гистограмма предполагает следующую (как правило смещенную) оценку функции плотности в точке $t \in b_k$:

$$\hat{f}_{X_i}(t) = \frac{1}{nh} \sum_{i=1}^n I(X_i \in b_k)$$

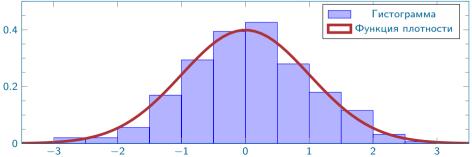
• Эффективность оценки зависит от параметра h. Существуют различные подходы к подбору оптимального значения данного параметра, например, по правилу Райса (Rice rule) $h=2n^{1.5}$.

Гистограмма

- Гистограмма является оценкой функции плотности.
- ullet Разобьем выборку на m интервалов равной длины h, где интервал обозначим как b_k .
- ullet Гистограмма предполагает следующую (как правило смещенную) оценку функции плотности в точке $t \in b_k$:

$$\hat{f}_{X_i}(t) = \frac{1}{nh} \sum_{i=1}^n I(X_i \in b_k)$$

• Эффективность оценки зависит от параметра h. Существуют различные подходы к подбору оптимального значения данного параметра, например, по правилу Райса (Rice rule) $h=2n^{1.5}$.



Ядерное оценивание

• Функция плотности при помощи ядер оценивается следующим образом:

$$\hat{f}_{X_1}(t) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{t - x_i}{h}\right)$$

Ядерное оценивание

• Функция плотности при помощи ядер оценивается следующим образом:

$$\hat{f}_{X_1}(t) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{t - x_i}{h}\right)$$

• Функция K является неотрицательной и именуется **ядром**. В качестве нее часто используют функцию плотности стандартного нормального распределения $K = \phi(t)$ (гауссовское ядро).

Ядерное оценивание

• Функция плотности при помощи ядер оценивается следующим образом:

$$\hat{f}_{X_1}(t) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{t - x_i}{h}\right)$$

- Функция K является неотрицательной и именуется **ядром**. В качестве нее часто используют функцию плотности стандартного нормального распределения $K = \phi(t)$ (гауссовское ядро).
- ullet Параметр h именуется **шириной окна** и его подбирают из соображения максимизации эффективности.

Ядерное оценивание

• Функция плотности при помощи ядер оценивается следующим образом:

$$\hat{f}_{X_1}(t) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{t - x_i}{h}\right)$$

- Функция K является неотрицательной и именуется **ядром**. В качестве нее часто используют функцию плотности стандартного нормального распределения $K = \phi(t)$ (гауссовское ядро).
- Параметр h именуется **шириной окна** и его подбирают из соображения максимизации эффективности.

